

Avril 2024

Apprentissage automatique : une introduction

Dr Ing. Houndji V. Ratheil

<https://ratheil.info>

Lecturer-Researcher at UAC



Houndji Vinasetan Ratheil

<https://ratheil.info>

Teaching experience (since my PhD thesis)

- Artificial Intelligence since 2014
- Optimisation since 2015
- Object Oriented Modelling/Programming
- Reliability of Information System
- etc.

Head of Software Engineering department at IFRI, UAC

Clarification de quelques concepts



Intelligence artificielle

Programmation déclarative

Programmation
par contraintes

Programmation
logique

Etc.

Théorie des jeux

Etc.

Meta-heuristiques

Traitement automatique
du langage

Vision par
ordinateur

Robotics

Expert systems

Apprentissage automatique

Apprentissage
automatique
supervisé

Apprentissage
automatique
non supervisé

Apprentissage
profond

Etc.

Apprentissage par
renforcement

Etc.

Plan

Introduction générale

Types d'apprentissage

Pré-traitement des données



Evaluation des modèles

Exemples pratiques


Apprentissage automatique ?




Apprentissage automatique ?



Apprentissage automatique ?




Apprentissage automatique ?



Le domaine d'étude qui donne à la machine la capacité d'apprendre sans être explicitement programmé
(Arthur Samuel, 1956)


Apprentissage automatique ?



Le domaine d'étude qui donne à la machine la capacité d'apprendre sans être explicitement programmé
(Arthur Samuel, 1956)

L'étude des algorithmes qui améliorent leur performances P pour une tâche T avec l'expérience E .
(Tom Mitchell, 1988)

Applications



Applications



Et beaucoup d'autres applications...

Plan

Introduction générale

Types d'apprentissage

Pré-traitement des données

Evaluation des modèles

Exemples pratiques



Plan

Types d'apprentissage


Apprentissage supervisé

Apprentissage non supervisé

Apprentissage sémi-supervisé

Apprentissage par renforcement

Types d'apprentissage



Apprentissage supervisé




L'IA apprend à partir d'exemples qui sont clairement étiquetés/labelisés. L'objectif est de prédire les étiquettes pour les nouvelles entrées basées sur ce qu'il a appris à partir des données d'entraînement.

Classification: les étiquettes sont des catégories / données qualitatives

Red Apple Category 1					
Red Apple Category 2					
Red Apple Category 3					
Red Apple Category 4					
Red Apple Category 5					
Banana					
Orange					
Pomegranate					

Regression: les étiquettes sont des réels / données quantitatives



Apprentissage non-supervised



La “machine” apprend à partir de données non étiquetées.

Clustering : regrouper les données qui sont “similaires”.



Association rules : trouver des règles dans un ensemble de “transactions”.

Transaction 1	   
Transaction 2	  
Transaction 3	 
Transaction 4	 
Transaction 5	   
Transaction 6	  
Transaction 7	 
Transaction 8	 

Apprentissage non-supervised



La “machine” apprend à partir de données non étiquetées.

Détection d'anomalies :

Réduction de la dimensionnalité :

Apprentissage sémi-supervisé




Un mélange de supervisé et de non supervisé :
certaines données sont étiquetées et la grande majorité non.


Apprentissage par renforcement



Il permet aux machines de déterminer automatiquement le comportement idéal dans un contexte spécifique en fonction des retours de l'environnement, afin de maximiser les performances.



Types d'apprentissage



Plan

Introduction générale

Types d'apprentissage

Pré-traitement des données

Evaluation des modèles

Exemples pratiques



Plan

Pré-traitement des données

Données manquantes / aberrantes

Variables de catégorie

Mise à l'échelle des variables

Données d'entraînement et de test

Données manquantes



Supprimer les lignes qui ont un certain pourcentage de données manquantes

Remplacer par la moyenne/médiane de la colonne

Considérer la valeur la plus fréquente de la colonne (ou d'une certaine catégorie)

Etc.

**Il est recommandé d'avoir l'avis d'un expert du domaine
de la problématique à résoudre.**

Variables de catégorie



Les variables de catégorie sont des variables qui contiennent des valeurs **non-numériques**. Il faut donc les encoder en valeurs numériques.

Pour les variables nominales, il faudrait les encoder en numérique sans que le poids n'affecte l'apprentissage (si une valeur n'est pas supérieure à l'autre).

Gender	Age	EstimatedSalary
Male	19	19000
Male	35	20000
Female	26	43000
Female	27	57000
Male	19	76000
Male	27	58000



Male	Female	Age	EstimatedSalary
1	0	19	19000
1	0	35	20000
0	1	26	43000
0	1	27	57000
1	0	19	76000
1	0	27	58000

Mise à l'échelle des variables



User ID	Gender	Age	EstimatedSalary	Purchased
15624510	Male	19	19000	0
15810944	Male	35	20000	0
15668575	Female	26	43000	0
15603246	Female	27	57000	0
15804002	Male	19	76000	0
15728773	Male	27	58000	0
15598044	Female	27	84000	0
15694829	Female	32	150000	1
15600575	Male	25	33000	0
15727311	Female	35	65000	0

Valeurs trop élevées
par rapport à celles de la
variable Age.

Min Max Scaler

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Standard Scaler

$$X_{new} = \frac{X_i - X_{mean}}{\text{Standard Deviation}}$$

Max Abs Scaler

Robust Scaler

Quantile Transformer Scaler


Power Transformer Scaler

Unit Vector Scaler

Training/Test sets



Pour l'apprentissage supervisé, il faut séparer dès le départ les données d'entraînement des données de test. En général, 70-80% des données pour l'entraînement et 20-30% pour les tests.



On pourrait aussi avoir dans l'ensemble d'entraînement des données de validation.

Plan

Introduction générale

Types d'apprentissage

Pré-traitement des données

Evaluation des modèles

Un exemple pratique



Outline

Evaluation

Classification

Regression

Clustering

Evaluation - Classification



Matrice de confusion

		Classe réelle	
		-	+
Classe prédite	-	True Negatives <i>(vrais négatifs)</i>	False Negatives <i>(faux négatifs)</i>
	+	False Positives <i>(faux positifs)</i>	True Positives <i>(vrais positifs)</i>

Application sur un modèle de prédiction de fraude douanière ?

Evaluation - Classification



Matrice de confusion

		Classe réelle	
		-	+
Classe prédite	-	True Negatives (vrais négatifs)	False Negatives (faux négatifs)
	+	False Positives (faux positifs)	True Positives (vrais positifs)

<i>Fraudeur ? (1 si oui, 0 si non)</i>	<i>Valeur prédite par l'IA</i>
1	0
1	1
0	0
1	0
0	1
1	0
1	1

TP = ?

FP = ?

TN = ?

FN = ?

Evaluation - Classification



$$\text{Accuracy} = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

TP = True positive

TN = True negative

$$\text{Recall} = \frac{TP}{TP + FN}$$

FP = False positive

FN = False negative

$$F1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

Evaluation - Régression



$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$


$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{SSR}{SST} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Predicted Value



Evaluation - Clustering



SSE

Silhouette Analysis

Plan

Introduction générale

Types d'apprentissage

Pré-traitement des données

Evaluation des modèles

Exemples pratiques





Pandas

Numpy

Python

Matplotlib

Scikit-learn

Anaconda

<https://www.anaconda.com/products/individual>

Avril 2024

Apprentissage supervisé : une introduction

Dr Ing. Houndji V. Ratheil

<https://ratheil.info>

Plan

Un exemple en apprentissage supervisé

Principales étapes

Principales étapes

Un petit exemple pratique avec KNN

Principales étapes / AA supervisé



Trouver ou construire le dataset adapté au problème

Importer les données

Nettoyer les données

Séparer les données en données d'entraînement et données de test
(si apprentissage supervisé)

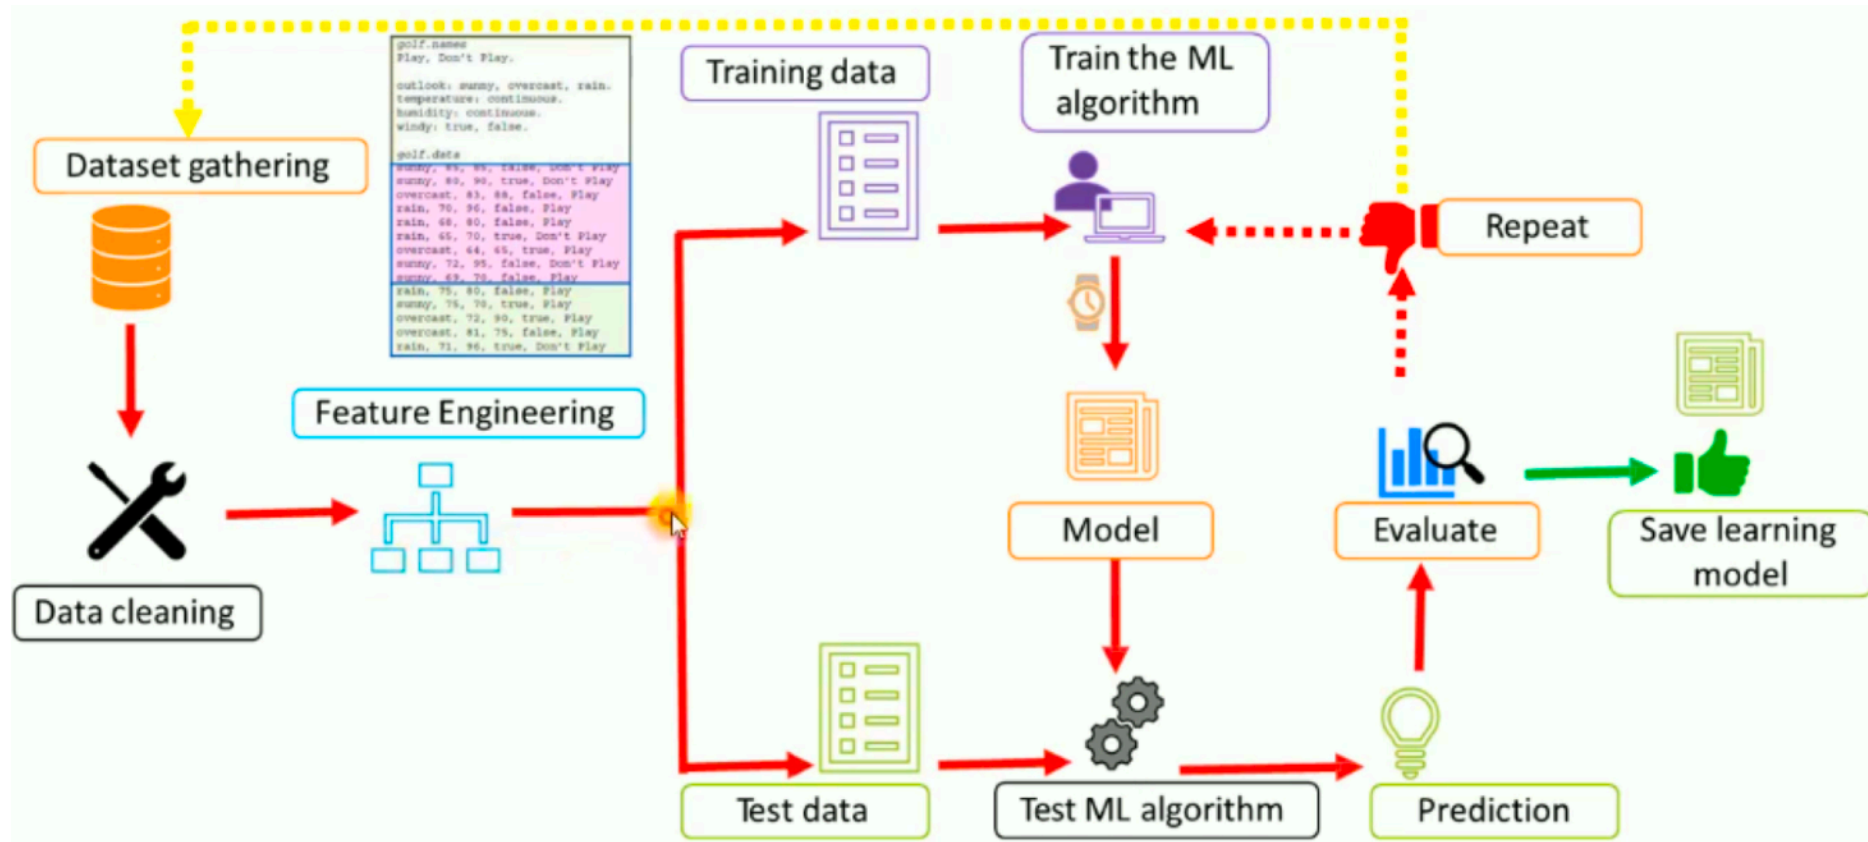
Implementer les modèles

Entraîner les modèles sur les données d'entraînement

Evaluer les modèles sur l'ensemble de test
(choisir les meilleurs hyperparamètres)

Mettre en production les modèles

Principales étapes / AA supervisé




Un mot sur KNN



L'algorithme des k plus proches voisins (k-nearest neighbors, ou KNN en abrégé) est un algorithme d'apprentissage machine utilisé à la fois pour la classification et la régression.

Il est basé sur un principe simple mais puissant : les instances similaires sont susceptibles de se regrouper dans des espaces similaires.



Un mot sur KNN



- **Entraînement** : l'algorithme KNN stocke simplement les exemples d'entraînement.
- **Prédiction** :
 - Lorsqu'une nouvelle observation doit être classée ou prédite, l'algorithme mesure la similarité entre cette observation et les exemples d'entraînement en utilisant une mesure de distance (souvent la distance euclidienne).
 - Il identifie les k exemples les plus proches de l'observation en termes de distance.
- **Classification ou Régression** :
 - En cas de classification, l'algorithme attribue la classe majoritaire parmi les k voisins à la nouvelle observation.
 - En cas de régression, il peut retourner la moyenne des valeurs cibles des k voisins pour prédire la valeur continue associée à la nouvelle observation.
- **Choix de l'hyper-paramètre k** :
 - Le choix de la valeur de k est crucial. Une valeur trop petite peut rendre l'algorithme sensible au bruit, tandis qu'une valeur trop grande peut introduire une influence excessive de points éloignés.

KNN : Application



K = 3

Height	Age	Weight
6	40	60
6,11	26	55
5,9	30	56
5,8	32	78
5,3	33	75
5,6	34	78
5,5	35	80
5,8	37	?

1. Appliquer k-NN
sans normalisation.

2. Appliquer k-NN
avec normalisation.

Utiliser pour la normalisation :

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

TP avec KNN



User ID	Gender	Age	EstimatedSalary	Purchased
15624510	Male	19	19000	0
15810944	Male	35	20000	0
15668575	Female	26	43000	0
15603246	Female	27	57000	0
15804002	Male	19	76000	0
15728773	Male	27	58000	0
15598044	Female	27	84000	0
15694829	Female	32	150000	1
15600575	Male	25	33000	0
15727311	Female	35	65000	0
15570769	Female	26	80000	0
15606274	Female	26	52000	0
15746139	Male	20	86000	0
15704987	Male	32	18000	0
15628972	Male	18	82000	0
15697686	Male	29	80000	0
15733883	Male	47	25000	1

Classification avec KNN

Voir l'impact de certains pré-traitements faits sur la qualité de l'apprentissage.

KNN



Mai 2024

Apprentissage supervisé : arbre de décision

Dr Ing. Houndji V. Ratheil


<https://ratheil.info>

Un mot sur les arbres de décision



En théorie des graphes, **arbre** = graphe non orienté, acyclique et connexe.

- Nœud *racine* (l'accès à l'arbre est effectué par ce nœud),
- Nœuds *internes*: nœuds ayant des descendants (ou *enfants*), étant sont à leur tour des nœuds,
- Nœuds *terminaux* (ou *feuilles*): nœuds n'ayant aucun descendant.



Un mot sur les arbres de décision




Arbre de décision : catégorie d'arbre utilisée en apprentissage automatique et en informatique décisionnelle.

- Emploi d'une représentation hiérarchique de la structure des données sous forme de séquences de décisions (tests) en vue de la prédiction d'un résultat ou d'une classe.
- Chaque individu (ou observation), devant être attribué(e) à une classe ou une valeur numérique, décrit(e) par un ensemble de variables testées dans les nœuds de l'arbre. Tests effectués dans les nœuds internes ; décisions prises dans les nœuds feuilles.

Arbre de classification

Arbre de regression

Un mot sur les arbres de décision



- Les nœuds de l'arbre testent les attributs
- Il y a une branche pour chaque valeur de l'attribut testé
- Les *feuilles* indiquent les catégories

Un exemple avec ID3



- **ID3** (Iterative Dichotomiser 3): développé en 1986 par Ross Quinlan. Applicable seulement sur les caractéristiques nominales.
- **C4.5**: une extension de ID3 par Ross Quinlan. Applicable sur tous les types de caractéristiques.
- **C5.0**: une extension commerciale de C4.5, toujours par Ross Quinlan.
- **CART** (Classification and Regression Trees): comme C4.5 mais utilise d'autres métriques. L'algorithme supporte la régression.

DT: Processus de construction



PROCEDURE DT(T, N)

SI tous les exemples de N sont dans la même classe C_i ALORS
affecter l'étiquette C_i au noeud courant // noeud feuille
FIN

SINON

sélectionner un attribut A avec les valeurs $v_1, v_2, \dots, v_n$

Partitionner N selon $v_1, v_2, \dots, v_n$ en $N_1, N_2, \dots, N_n$


Pour $j = 1$ à n FAIRE

DT(T_j, N_j)

FIN POUR

FIN SI

FIN PROCEDURE



Un exemple avec ID3



Iterative Dichotomiser 3 (ID3)

Famille TDIDT (Top Down Induction of Decision Trees).

Approche descendante: on part d'une racine de l'arbre et on raffine.

Algorithme gourmand:

Recherche en meilleur d'abord (avec une fonction d'évaluation)
sans retour arrière.

ID3: Choix de la variable



La variable qui discrimine le plus, la variable la plus “pure”.

Plusieurs approches pour mesurer cette pureté.

Exemple: **Gain d'information** basé sur la mesure de l'entropie.

Entropie: elle mesure le degré de désordre ou d'incertitude dans un ensemble de données. Pour un ensemble de données S

$$H(S) = - \sum_{i=1}^k p(C_i) \log_2 p(C_i)$$

où $p(C_i)$ est la proportion des instances de la classe C_i dans S .

Gain d'information: il mesure la réduction de l'entropie obtenue en partitionnant l'ensemble de données selon un attribut particulier. Pour un attribut A , le gain d'information est défini comme :

$$Gain(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

où S_v est le sous-ensemble de S pour lequel l'attribut A prend la valeur v .

ID3 : TD



Construire l'arbre de décision associé à ce dataset.

Temps	Température	Jouer Dehors
Ensoleillé	Chaud	Non
Ensoleillé	Modéré	Oui
Nuageux	Chaud	Oui
Pluvieux	Modéré	Non
Pluvieux	Froid	Non
Nuageux	Modéré	Oui
Ensoleillé	Froid	Non
Nuageux	Froid	Oui
Pluvieux	Chaud	Non
Ensoleillé	Chaud	Non

$$H(S) = - \sum_{i=1}^k p(C_i) \log_2 p(C_i)$$

$$Gain(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

TP sur les arbres de décision



User ID	Gender	Age	EstimatedSalary	Purchased
15624510	Male	19	19000	0
15810944	Male	35	20000	0
15668575	Female	26	43000	0
15603246	Female	27	57000	0
15804002	Male	19	76000	0
15728773	Male	27	58000	0
15598044	Female	27	84000	0
15694829	Female	32	150000	1
15600575	Male	25	33000	0
15727311	Female	35	65000	0
15570769	Female	26	80000	0
15606274	Female	26	52000	0
15746139	Male	20	86000	0
15704987	Male	32	18000	0
15628972	Male	18	82000	0
15697686	Male	29	80000	0
15733883	Male	47	25000	1

Classification avec les arbres de décision avec scikit-learn.


Arbre de décision : hyperparamètres



Arbre de décision



Un mot sur les forêts aléatoires



Avril 2024

Clustering : une introduction

Dr Ing. Houndji V. Ratheil

<https://ratheil.info>

Plan

Un exemple en apprentissage non supervisé

Un mot sur le clustering


Algorithme K-means

Un petit exemple pratique avec K-means

Un mot sur le clustering



Le clustering, ou partitionnement de données, est une méthode d'analyse exploratoire de données utilisée pour identifier des structures ou des groupes distincts (clusters) au sein d'un ensemble de données.




Un mot sur le clustering



Un cluster est un ensemble de points de données similaires qui sont regroupés en fonction de la mesure de similarité choisie.

L'objectif est de :

- maximiser la similarité intra-cluster;
- minimiser la similarité inter-cluster.



Clustering : quelques applications



1. **Segmentation de marché** : Identifier des groupes de clients avec des caractéristiques similaires pour le marketing ciblé.
2. **Organisation de documents** : Regrouper des documents similaires pour la recherche d'informations et la gestion de la connaissance.
3. **Imagerie médicale** : Segmenter différentes parties d'une image médicale pour aider à l'identification des tissus, des maladies ou des anomalies.
4. **Biologie computationnelle** : Classer des organismes ou des gènes en groupes qui partagent des fonctions similaires ou des profils d'expression.
5. **Analyse de réseaux sociaux** : Détecter des communautés ou des groupes dans les réseaux sociaux basés sur des connexions ou des interactions communes.
6. **Segmentation d'images** : Diviser une image numérique en segments pour simplifier et/ou changer la représentation de l'image en quelque chose de plus significatif et plus facile à analyser.
7. **Recommandation de produits** : Regrouper les utilisateurs en fonction de leurs préférences d'achat ou de visualisation pour recommander des produits ou des médias similaires.
8. **Détection de fraudes** : Identifier des activités ou des comportements suspects en groupant des transactions ou des actions similaires.

Etc.

Etc.

Clustering : plus formellement



Soit n le nombre de points de données dans notre ensemble de données.

Soit $C_1, C_2, \dots, C_k$

représentant les ensembles contenant les indices des observations dans chaque cluster.

Chaque point de données appartient à un et un seul cluster.

$$C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}.$$

$$C_k \cap C_{k'} = \emptyset, \text{ pour tout } k \text{ et } k'.$$

Avec W le plus petit possible

$$W = \sum_{k=1}^K \frac{1}{|C_k|} \sum_{C(i)=k, C(j)=k} d_{ij}$$

Clustering : distances



1. Distance Euclidienne :

- La plus courante et la plus intuitive pour de nombreux cas d'utilisation, elle correspond à la distance "à vol d'oiseau" entre deux points dans un espace euclidien.
- Calcul : $\sqrt{\sum_{i=1}^n (x_i - y_i)^2}$

2. Distance de Manhattan (ou Distance Taxicab) :

- Utile pour les grilles de ville ou les systèmes de coordonnées où l'on ne peut se déplacer que le long des axes et non en diagonale.
- Calcul : $\sum_{i=1}^n |x_i - y_i|$

3. Distance de Minkowski :

- Généralisation des distances Euclidienne et de Manhattan, elle ajoute un paramètre p qui permet de régler la mesure de distance.
- Calcul : $(\sum_{i=1}^n |x_i - y_i|^p)^{1/p}$

4. Distance de Chebyshev :

- Pertinente lorsque la distance est déterminée par la différence la plus significative entre deux éléments.
- Calcul : $\max_i |x_i - y_i|$

Etc.

Etc.

Clustering : algorithmes




K-means

Clustering hiérarchique / dendogramme

DBSCAN

Etc.

Etc.




K-means : Principe



L'algorithme K-means est une méthode simple pour diviser un ensemble de données en K clusters distincts et non chevauchants.

Pour réaliser un clustering K-means, nous devons d'abord spécifier le nombre souhaité de clusters K et la mesure de distance.

Ensuite, l'algorithme K-means attribuera chaque observation à exactement un des K clusters.



K-means : Principe de base



1. **1. Choix du nombre de clusters k**
2. **2. Initialisation des centroids** : Sélectionnez k points aléatoires de l'ensemble des données comme centroids initiaux. Cette sélection peut être améliorée pour éviter des clusters mal équilibrés.
3. **3. Attribution des points aux clusters** :
 - Pour chaque point dans l'ensemble de données, calculez la distance entre ce point et chaque centroid.
 - Attribuez chaque point au cluster dont le centroid est le plus proche avec la métrique de distance choisie.
4. **4. Mise à jour des centroids** :
 - Une fois tous les points attribués à un cluster, recalculez la position des centroids pour chaque cluster. Le nouveau centroid d'un cluster est calculé en prenant la moyenne de tous les points qui ont été attribués à ce cluster lors de l'étape précédente.
5. **5. Répétition** :
 - Répétez les étapes d'attribution des points et de mise à jour des centroids jusqu'à ce que le critère d'arrêt soit satisfait, typiquement lorsque les centroids ne changent plus (ou ne changent que très peu) entre les itérations, ou après un nombre prédéfini d'itérations.

K-means : Evaluation



L'inertie est définie comme la somme des distances au carré entre chaque point et le centroïde de son cluster. Mathématiquement, cela peut être exprimé comme suit :

$$\text{Inertie} = \sum_{i=1}^n \min_{\mu_j \in C} (\|x_i - \mu_j\|^2)$$

où x_i est un point de données, μ_j est le centroïde du cluster C auquel x_i a été assigné, et $\|x_i - \mu_j\|$ est la distance euclidienne entre x_i et μ_j .

K-means : Application





Considérons le dataset suivant.

x	y
1	1
1.5	2
3	4
5	7
3.5	5
4.5	5
3.5	4.5
4	4

- Distance euclidienne
- Nombre de clusters : 2
- Centroïdes de départ : (3, 4) et (4.5, 5)

K-means : Application



K-means : Comment choisir le k ?




La méthode du coude (ou Elbow Method) est une technique utilisée pour déterminer le nombre optimal de clusters dans un algorithme de clustering K-means.

La méthode du coude examine la variation du WCSS en fonction du nombre de clusters choisi.

L'idée est de trouver un point où augmenter le nombre de clusters n'entraîne pas une amélioration significative de la somme des carrés des distances.

Elbow method



TP avec K-means



K-means



Quelques repos de datasets

Kaggle: <https://www.kaggle.com/datasets>

UCI Machine Learning Repository:
<https://archive.ics.uci.edu/ml/index.php>

Microsoft datasets: <https://msropendata.com/>

Awesome public datasets:
<https://github.com/awesomedata/awesome-public-datasets>

Scikit learn datasets:
<https://scikit-learn.org/stable/datasets/index.html>

Google's Dataset Search Engine: <https://datasetsearch.research.google.com/>